

# COE-835 Controle adaptativo

## Trabalho 7

**Grupo:** Guilherme Pires Sales de Carvalho  
Matheus Ferreira dos Reis  
Renan Salles de Freitas

**Algoritmo:** Adaptive Backstepping Control

**Caso:**  $n = 2$  (ordem da planta)  
 $n^* = 2$  (grau relativo)  
 $n_p = 3$  (# de parâmetros)

## Conteúdo

<b>1</b>	<b>Backstepping - Formulação teórica sem observador</b>	<b>2</b>
<b>2</b>	<b>Backstepping - Formulação teórica com observador</b>	<b>4</b>
<b>3</b>	<b>Implementação</b>	<b>6</b>
<b>4</b>	<b>Resultados das simulações</b>	<b>8</b>
4.1	Simulação #1 . . . . .	8
4.2	Simulação #2 . . . . .	11
4.3	Simulação #3 . . . . .	13
<b>5</b>	<b>Discussão</b>	<b>17</b>

## 1 Backstepping - Formulação teórica sem observador

Backstepping é um método recursivo de controle adaptativo baseado em Lyapunov e proposto no começo da década de 90. A ideia é projetar um controle recursivo considerando algumas das variáveis de estado como “controle virtuais” e implementar para elas leis de controle intermediárias. Com esta técnica é possível resolver problemas de estabilidade e rastreamento. Neste trabalho, desenvolveremos a fundamentação teórica para o caso de um sistema de segunda ordem com parâmetros desconhecidos:

$$\begin{aligned}\dot{x}_1 &= x_2 + \phi_1^T(x_1) \theta \\ \dot{x}_2 &= k_p u + \phi_2^T(x_1, x_2) \theta\end{aligned}\tag{1}$$

onde  $\theta$  é o vetor de parâmetros desconhecidos e  $k_p$  é o ganho de alta frequência, também desconhecido. As não linearidades do sistema são representadas pela variável  $\phi$ . Para o desenvolvimento do algoritmo, assume-se:

- o sinal de  $k_p$  é conhecido;
- o sinal de referência  $y_r$  e suas derivadas são contínuas e limitadas.

Introduzem-se as variáveis  $\mathbf{z}$  (mudança de coordenadas):

$$\begin{aligned}z_1 &= x_1 - y_r \\ z_2 &= x_2 - \alpha_1 - \dot{y}_r,\end{aligned}\tag{2}$$

onde  $\alpha$  é a variável de controle virtual. O primeiro passo para a elaboração do método é começar pela equação 2, considerando  $x_2$  como uma variável de controle virtual. A derivada do erro de rastreamento  $z_1$  é dada por:

$$\begin{aligned}\dot{z}_1 &= \dot{x}_1 - \dot{y}_r \\ &= z_2 + \alpha_1 + \phi_1^T \theta\end{aligned}\tag{3}$$

Podemos projetar a primeira função estabilizante  $\alpha_1$  como:

$$\alpha_1 = -c_1 z_1 - \phi_1^T \hat{\theta},\tag{4}$$

onde  $c_1$  é uma constante positiva e  $\hat{\theta}$  é uma estimativa de  $\theta$ . Consideremos a função de Lyapunov:

$$V_1 = \frac{1}{2} z_1^2 + \frac{1}{2} \tilde{\theta}^T \Gamma^{-1} \tilde{\theta},\tag{5}$$

onde  $\Gamma$  é uma matriz positiva definida e  $\tilde{\theta} = \theta - \hat{\theta}$ . Derivando a função de Lyapunov, temos:

$$\dot{V}_1 = z_1 \dot{z}_1 - \tilde{\theta}^T \Gamma^{-1} \dot{\tilde{\theta}}\tag{6}$$

$$\begin{aligned}&= z_1 (z_2 + \alpha_1 + \phi_1^T \hat{\theta}) - \tilde{\theta}^T (\Gamma^{-1} \dot{\tilde{\theta}} - \phi_1 z_1) \\ &= -c_1 z_1^2 + \tilde{\theta}^T (\tau_1 - \Gamma^{-1} \dot{\tilde{\theta}}) + z_1 z_2 \\ \tau_1 &= \phi_1 z_1\end{aligned}\tag{7}$$

Observe que se escolhermos a variação dos parâmetros como  $\dot{\hat{\theta}} = \Gamma \tau_1$  anulamos um dos termos, mas ainda falta considerar a dinâmica de  $z_2$ . Devemos deixar a escolha da lei de adaptação em aberto. Pela segunda equação, temos:

$$\begin{aligned} \dot{z}_2 &= k_p u + \phi_2^\top \theta - \dot{\alpha}_1 - \ddot{y}_r \\ &= k_p u + \phi_2^\top \theta - \frac{\partial \alpha_1}{\partial x_1} (x_2 + \phi_1^\top \theta) - \frac{\partial \alpha_1}{\partial \hat{\theta}} \dot{\hat{\theta}} - \frac{\partial \alpha_1}{\partial y_r} \dot{y}_r - \ddot{y}_r \end{aligned} \quad (8)$$

Escolhemos a função Lyapunov:

$$V = V_1 + \frac{1}{2} z_2^2 + \frac{|k_p|}{2\gamma} \tilde{p}^2, \quad (9)$$

onde  $\tilde{p} = p - \hat{p}$  e  $\hat{p}$  é estimativa de  $p = \frac{1}{k_p}$ , e  $\gamma > 0$ . Derivando a função Lyapunov, obtemos:

$$\begin{aligned} \dot{V} &= -c_1 z_1^2 + z_1 z_2 + \tilde{\theta}^\top (\tau_1 - \Gamma^{-1} \dot{\hat{\theta}}) + z_2 \dot{z}_2 + \frac{|k_p|}{\gamma} \tilde{p} \dot{\tilde{p}} \\ &= -c_1 z_1^2 + z_1 z_2 + \tilde{\theta}^\top (\tau_1 - \Gamma^{-1} \dot{\hat{\theta}}) + z_2 \left( k_p u + \phi_2^\top \theta - \frac{\partial \alpha_1}{\partial x_1} (x_2 + \phi_1^\top \theta) - \frac{\partial \alpha_1}{\partial \hat{\theta}} \dot{\hat{\theta}} - \frac{\partial \alpha_1}{\partial y_r} \dot{y}_r - \ddot{y}_r \right) + \frac{|k_p|}{\gamma} \tilde{p} \dot{\tilde{p}} \\ \theta &= \tilde{\theta} + \hat{\theta} \\ \dot{V} &= -c_1 z_1^2 + z_1 z_2 + \tilde{\theta}^\top (\tau_1 - \Gamma^{-1} \dot{\hat{\theta}}) + z_2 \left( k_p u + (\tilde{\theta}^\top + \hat{\theta}^\top) (\phi_2 - \frac{\partial \alpha_1}{\partial x_1} \phi_1) - \frac{\partial \alpha_1}{\partial x_1} x_2 \right. \\ &\quad \left. - \frac{\partial \alpha_1}{\partial \hat{\theta}} \dot{\hat{\theta}} - \frac{\partial \alpha_1}{\partial y_r} \dot{y}_r - \ddot{y}_r \right) + \frac{|k_p|}{\gamma} \tilde{p} \dot{\tilde{p}} \\ \tau_2 &= \tau_1 + \left( \phi_2 - \frac{\partial \alpha_1}{\partial x_1} \phi_1 \right) z_2 \\ \dot{V} &= -c_1 z_1^2 + z_1 z_2 + \tilde{\theta}^\top (\tau_2 - \Gamma^{-1} \dot{\hat{\theta}}) + z_2 \left( k_p u + \hat{\theta}^\top (\phi_2 - \frac{\partial \alpha_1}{\partial x_1} \phi_1) - \frac{\partial \alpha_1}{\partial x_1} x_2 \right. \\ &\quad \left. - \frac{\partial \alpha_1}{\partial \hat{\theta}} \dot{\hat{\theta}} - \frac{\partial \alpha_1}{\partial y_r} \dot{y}_r - \ddot{y}_r \right) + \frac{|k_p|}{\gamma} \tilde{p} \dot{\tilde{p}} \end{aligned} \quad (10)$$

Escolhemos a lei de controle:

$$u = \hat{p} \bar{u} \quad (11)$$

$$\bar{u} = \alpha_2 + \ddot{y}_r \quad (12)$$

Note que:

$$k_p u = k_p \hat{p} \bar{u} = \bar{u} - k_p \tilde{p} \bar{u} \quad (13)$$

Substituindo a eq.13 em eq.10, temos:

$$\begin{aligned}
\dot{V} &= -c_1 z_1^2 + z_1 z_2 + \tilde{\theta}^\top (\tau_2 - \Gamma^{-1} \dot{\hat{\theta}}) + z_2 \left( \bar{u} - k_p \tilde{p} \bar{u} + \hat{\theta}^\top (\phi_2 - \frac{\partial \alpha_1}{\partial x_1} \phi_1) - \frac{\partial \alpha_1}{\partial x_1} x_2 \right. \\
&\quad \left. - \frac{\partial \alpha_1}{\partial \hat{\theta}} \dot{\hat{\theta}} - \frac{\partial \alpha_1}{\partial y_r} \dot{y}_r - \ddot{y}_r \right) + \frac{|k_p|}{\gamma} \tilde{p} \dot{\hat{p}} \\
&= -c_1 z_1^2 + z_1 z_2 + \tilde{\theta}^\top (\tau_2 - \Gamma^{-1} \dot{\hat{\theta}}) + z_2 \left( \bar{u} + \hat{\theta}^\top (\phi_2 - \frac{\partial \alpha_1}{\partial x_1} \phi_1) - \frac{\partial \alpha_1}{\partial x_1} x_2 \right. \\
&\quad \left. - \frac{\partial \alpha_1}{\partial \hat{\theta}} \dot{\hat{\theta}} - \frac{\partial \alpha_1}{\partial y_r} \dot{y}_r - \ddot{y}_r \right) + \frac{|k_p|}{\gamma} \tilde{p} (\dot{\hat{p}} - \text{sign}(k_p) \gamma \bar{u} z_2)
\end{aligned} \tag{14}$$

$$\begin{aligned}
&= -c_1 z_1^2 + z_1 z_2 + \tilde{\theta}^\top (\tau_2 - \Gamma^{-1} \dot{\hat{\theta}}) + z_2 \left( \alpha_2 + \hat{\theta}^\top (\phi_2 - \frac{\partial \alpha_1}{\partial x_1} \phi_1) - \frac{\partial \alpha_1}{\partial x_1} x_2 \right. \\
&\quad \left. - \frac{\partial \alpha_1}{\partial \hat{\theta}} \dot{\hat{\theta}} - \frac{\partial \alpha_1}{\partial y_r} \dot{y}_r \right) - \frac{|k_p|}{\gamma} \tilde{p} (\dot{\hat{p}} + \text{sign}(k_p) \gamma \bar{u} z_2)
\end{aligned} \tag{15}$$

Escolhemos  $\alpha_2$  como:

$$\alpha_2 = -c_2 z_2 - z_1 - \hat{\theta}^\top (\phi_2 - \frac{\partial \alpha_1}{\partial x_1} \phi_1) + \frac{\partial \alpha_1}{\partial x_1} x_2 + \frac{\partial \alpha_1}{\partial \hat{\theta}} \dot{\hat{\theta}} + \frac{\partial \alpha_1}{\partial y_r} \dot{y}_r \tag{16}$$

Substituindo a eq.16 em eq.15, obtemos:

$$\dot{V} = -c_1 z_1^2 - c_2 z_2^2 + \tilde{\theta}^\top (\tau_2 - \Gamma^{-1} \dot{\hat{\theta}}) - \frac{|k_p|}{\gamma} \tilde{p} (\dot{\hat{p}} + \text{sign}(k_p) \gamma \bar{u} z_2) \tag{17}$$

A lei de atualização dos parâmetros é, portanto:

$$\dot{\hat{p}} = -\gamma \text{sign}(k_p) \bar{u} z_2 \tag{18}$$

$$\dot{\hat{\theta}} = \Gamma \tau_2 \tag{19}$$

## 2 Backstepping - Formulação teórica com observador

Neste trabalho, consideramos o sistema:

$$\dot{x}_1 = x_2 - a_1 y \tag{20}$$

$$\dot{x}_2 = k_p u - a_0 y$$

onde os parâmetros  $a_1$ ,  $a_0$  e  $k_p$  são desconhecidos. Para esta formulação apenas a saída do sistema  $y$  está disponível, portanto  $x_2$  não é conhecido e deve ser estimado. Podemos reescrever o sistema 21:

$$\dot{x} = Ax - F(y, u)^\top \theta$$

$$A = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}, F(y, u)^\top = [B(u) \quad \Phi(y)], \Phi(y) = \begin{bmatrix} -y & 0 \\ 0 & -y \end{bmatrix}, B(u) = \begin{bmatrix} 0 \\ u \end{bmatrix}, \theta = \begin{bmatrix} k_p \\ a_1 \\ a_0 \end{bmatrix}$$

$$y = e_1^\top x$$

$$e_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

(21)

Para estimar os estados, utilizamos os filtros abaixo:

$$\begin{aligned}\dot{\xi} &= A_0\xi + ky \\ \dot{\Xi}^\top &= A_0\Xi^\top + \Phi(y) \\ \dot{\lambda} &= A_0\lambda + e_2u \\ v_i &= A_0^i\lambda \\ k &= \begin{bmatrix} k_1 \\ k_2 \end{bmatrix}, A_0 = A - ke_1^\top = \begin{bmatrix} -k_1 & 1 \\ -k_2 & 0 \end{bmatrix}\end{aligned}\tag{22}$$

Os valores de  $k$  devem ser escolhidos de forma que  $A_0$  seja Hurwitz. O estado estimado é dado por:

$$\hat{x} = \xi + \Xi^\top\theta + \sum_{i=0}^m b_i v_i\tag{23}$$

Porém, este estimador não pode ser usado, pois  $\theta$  não é conhecido. A dinâmica do observador pode ser descrita como:

$$\begin{aligned}\dot{\hat{x}} &= \dot{\xi} + \dot{\Xi}^\top\theta + \sum_{i=0}^m b_i \dot{v}_i \\ &= (A_0\xi + ky) + (A_0\Xi^\top + \Phi)\theta + \sum_{i=0}^m b_i A_0^i (A_0\lambda + e_2u) \\ &= A_0(\xi + \Xi^\top\theta + \sum_{i=0}^m b_i v_i) + ky + \Phi\theta + Bu \\ &= A_0\hat{x} + ky + \Phi\theta + Bu\end{aligned}\tag{24}$$

Podemos reescrever a dinâmica da saída  $y$ :

$$\begin{aligned}\dot{y} &= x_2 + \phi^\top\theta \\ &= k_p v_{0,2} + \xi_2 + \bar{\omega}^\top\theta + \epsilon_2 \\ \bar{\omega}^\top &= [0 \quad (\Xi_2 + \phi_1^\top)]\end{aligned}\tag{25}$$

Desta forma, o sistema 21 pode ser representado com os estados do observador:

$$\dot{y} = k_p v_{0,2} + \xi_2 + \bar{\omega}^\top\theta + \epsilon_2\tag{26}$$

$$\dot{v}_{0,2} = u - k_2 v_{0,1}\tag{27}$$

O projeto backstepping agora segue como na seção anterior. Primeiro, fazemos a mudança de coordenadas em  $\mathbf{z}$ :

$$\begin{aligned}z_1 &= y - y_r \\ z_2 &= v_{0,2} - \alpha_1 - \hat{\rho}\dot{y}_r\end{aligned}\tag{28}$$

onde  $\rho$  é estimativa de  $\frac{1}{k_p}$ . Nessas condições, é possível mostrar por Lyapunov, usando o mesmo procedimento do caso com observador completo, que as variáveis de controle são:

$$\alpha_1 = \hat{\rho}\bar{\alpha}_1 \quad (29)$$

$$\bar{\alpha}_1 = -c_1 z_1 - d_1 z_1 - \xi_2 - \bar{\omega}^\top \hat{\theta} \quad (30)$$

$$\beta = k_2 v_{0,1} + \frac{\partial \alpha_1}{\partial y} (\xi + \omega^\top \hat{\theta}) + \frac{\partial \alpha_1}{\partial \eta} (A_0 \eta + e_2 y) + \frac{\partial \alpha_1}{\partial y_r} \dot{y}_r + (\dot{y}_r + \frac{\partial \alpha_1}{\partial \hat{\rho}}) \hat{\rho} \quad (31)$$

$$u = -c_2 z_2 + \beta + \hat{\rho} \ddot{y}_r + \frac{\partial \alpha_1}{\partial \hat{\theta}} \hat{\theta} - d_2 z_2 \left( \frac{\partial \alpha_1}{\partial y} \right)^2 - \hat{k}_p z_1 \quad (32)$$

E as atualizações dos parâmetros são:

$$\hat{\rho} = -\gamma z_1 \text{sign}(k_p)(\dot{y}_r + \bar{\alpha}_1) \quad (33)$$

$$\hat{\theta} = \Gamma \tau_2 \quad (34)$$

$$\tau_1 = (\omega - \hat{\rho}(\dot{y}_r + \bar{\alpha}_1)e_1)z_1 \quad (35)$$

$$\tau_2 = \tau_1 - z_2 \frac{\partial \alpha_1}{\partial y} \omega \quad (36)$$

### 3 Implementação

Para a implementação, só é preciso computar os filtros:

$$\dot{\lambda} = A_0 \lambda + e_2 u \quad (37)$$

$$\dot{\eta} = A_0 \eta + e_2 y \quad (38)$$

Pois é possível demonstrar que:

$$\Xi = -[A_0 \eta \quad \eta] \quad (39)$$

$$\xi = -A_0 \eta \quad (40)$$

$$v_0 = \lambda \quad (41)$$

Temos ainda que  $\alpha = \hat{\rho}(-c_1 z_1 - d_1 d_1 - \xi_2 - \bar{\omega}^\top \hat{\theta})$ . Logo:

$$\frac{\partial \alpha_1}{\partial y} = -\hat{\rho}(c_1 + d_1) + \hat{\rho} e_2^\top \hat{\theta} \quad (42)$$

$$\frac{\partial \alpha_1}{\partial \eta} = e_2^\top A_0^\top \hat{\rho} \quad (43)$$

$$\frac{\partial \alpha_1}{\partial y_r} = \hat{\rho}(c_1 + d_1) \quad (44)$$

$$\frac{\partial \alpha_1}{\partial \hat{\theta}} = -\rho \bar{\omega} \quad (45)$$

$$\frac{\partial \alpha_1}{\partial \hat{\rho}} = -(c_1 + d_1)(y - y_r) + e_2^\top A_0 \eta - \bar{\omega}^\top \hat{\theta} \quad (46)$$

```

1 %-----
2 %
3 % COE-835 Controle adaptativo
4 %
5 % Script para simular o trabalho 7
6 %

```

```

7 % Backstepping : n = 2      Second and third order plant
8 %               n* = 2      Relative degree
9 %               np = 3      Adaptive parameters
10 % Caso com observador completo
11 %-----
12
13 function dx = backstepping_obs(t,x)
14
15 global A B thetas A0 c1 c2 d1 d2 Gamma gamma kp a w e1 e2 k;
16
17 y          = x(1:2);
18 theta      = x(3:5);
19 lambda     = x(6:7);
20 eta        = x(8:9);
21 rho        = x(10);
22
23 %% Input
24 yr = a(1) * sin(w(1)*t) + a(2) * sin(w(2)*t);
25 dyr = a(1) * w(1) * cos(w(1)*t) + a(2) * w(2) * cos(w(2)*t);
26 ddyr = -a(1) * w(1)^2 * sin(w(1)*t) - a(2) * w(2)^2 * sin(w(2)*t);
27
28 Phi = [-y(1) 0;0 -y(1)];
29
30 %% Variables 1
31 xi = -A0^2 * eta;
32 Xi = -[A0*eta eta];
33 v1 = lambda(1);
34 v2 = lambda(2);
35 omega_bar = [0, (Xi(2,:) - y(1)*e1')]';
36 omega = [v2, (Xi(2,:) - y(1)*e1')]';
37
38 %% Z
39 z1 = y(1) - yr;
40 alpha_bar = -c1*z1 - d1*z1 - xi(2) - omega_bar'*theta;
41 alpha_1 = rho * alpha_bar;
42 z2 = v2 - rho*dyr - alpha_1;
43
44 %% dalpha/dt
45 dady = rho * (- c1 - d1 + [0,e1']*theta);
46 dadeta = rho * e2' * A0^2;
47 dadyr = rho*(c1 + d1);
48 dadtheta = - rho * omega_bar';
49 dadrho = -(c1 + d1)*(y(1) - yr) + e2'*A0^2*eta - omega_bar'*theta;
50
51
52 %% Variables 2
53 tau_1 = (omega - rho*(dyr + alpha_bar)*[e1',0]')*z1;
54 tau_2 = tau_1 - z2 * (dady * omega);
55
56 %% Atualização dos parâmetros
57 dtheta = Gamma * tau_2;
58 drho = - gamma * z1 * sign(kp) * (dyr + alpha_bar);
59 beta = k(2)*v1 + dady * (xi(2) + omega'*theta) + ...
60       dadeta * (A0*eta + e2*y(1)) + dadyr * dyr + (dyr + dadrho) * drho;
61 u = -c2*z2 + beta + rho*ddyr + dadtheta*dtheta - d2*z2*(dady)^2 - ...
62     theta(1)*z1;
63
64 %% Filtros
65 dlambda = A0*lambda + e2*u;

```

```

66 deta = A0*eta + e2*y(1);
67
68
69 %% Planta
70 F = [B*u Phi];
71 dy = A*y + F*thetas;
72
73 %% Translation
74 dx = [dy' dtheta' dlambda' deta' drho]';

```

## 4 Resultados das simulações

Nas simulações, procuramos avaliar o comportamento do sistema para as seguintes condições: (i) condições iniciais  $\theta(0)$  e  $y(0)$ ; (ii) Parâmetros da planta e do modelo; (iii) ganho de adaptação  $\Gamma$ .


Apresentaremos os resultados obtidos através de simulações no ambiente **Matlab/Simulink** e os discutiremos na próxima seção.

### 4.1 Simulação #1






Inicialmente, desejamos verificar o comportamento do sistema para variações nas condições iniciais.

#### Simulação 1.1: $\theta(0)$

$$y = \frac{5}{s^2 + 2s + 1}u, \quad \theta(0) = 0 \text{ e } 1, \quad y(0) = 0, \quad \Gamma = 1 \mathbf{I}_3, \\ y_r = \sin(t) + \sin(3t).$$







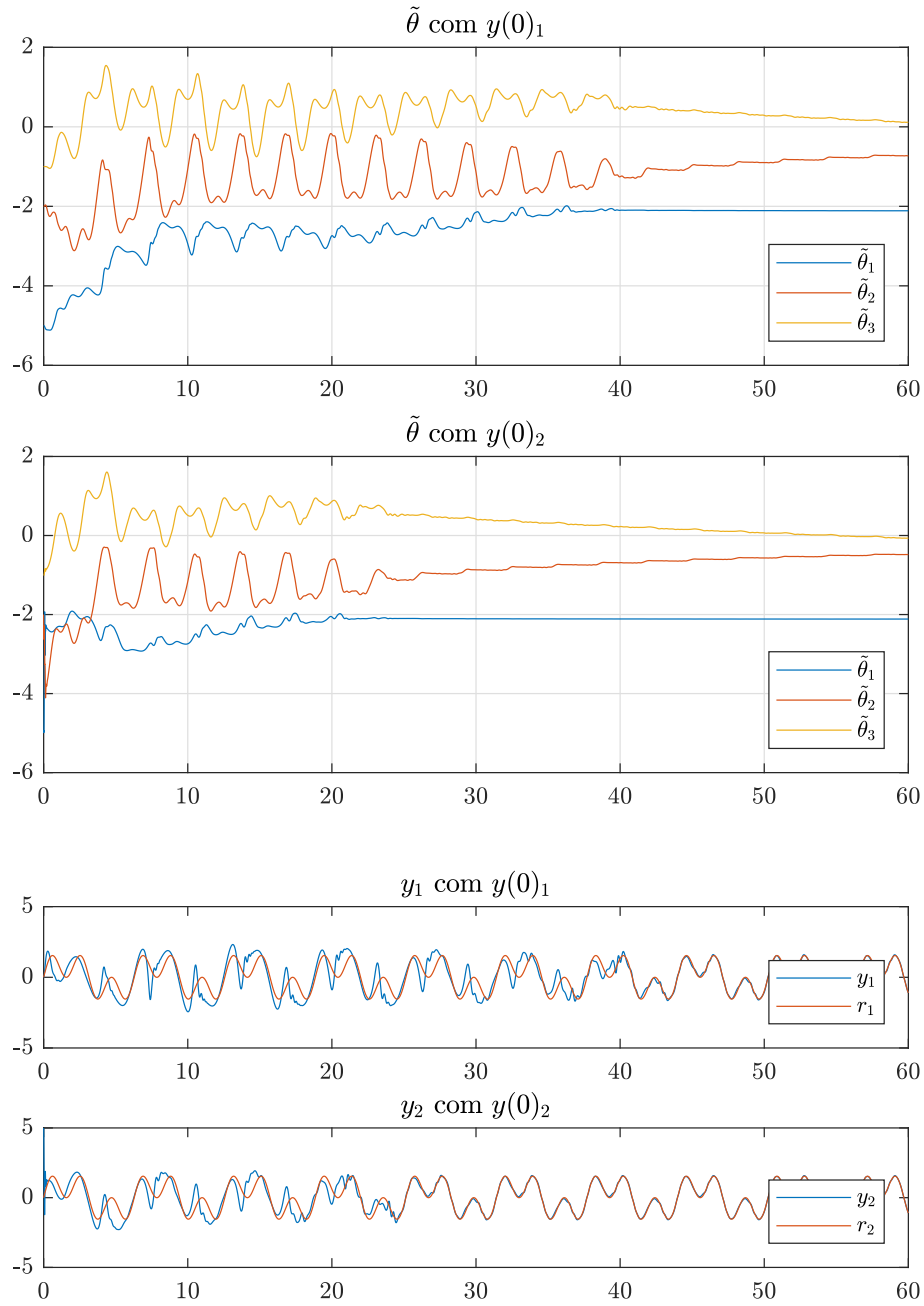


**Simulação 1.2:**  $y(0)$ 

$$y = \frac{5}{s^2 + 2s + 1}u, \quad \theta(0) = 0, \quad y(0) = 0 \text{ e } 5, \quad \Gamma = 1 \mathbf{I}_3,$$

$$y_r = \sin(t) + \sin(3t).$$










## 4.2 Simulação #2

Verificamos o comportamento do sistema para variações no parâmetro de adaptação  $\Gamma$ .

$$y = \frac{5}{s^2 + 2s + 1}u, \quad \theta(0) = 0, \quad y(0) = 0, \quad \Gamma = \mathbf{1} \text{ e } \mathbf{10} \mathbf{I}_3, \\ y_r = \sin(t) + \sin(3t).$$





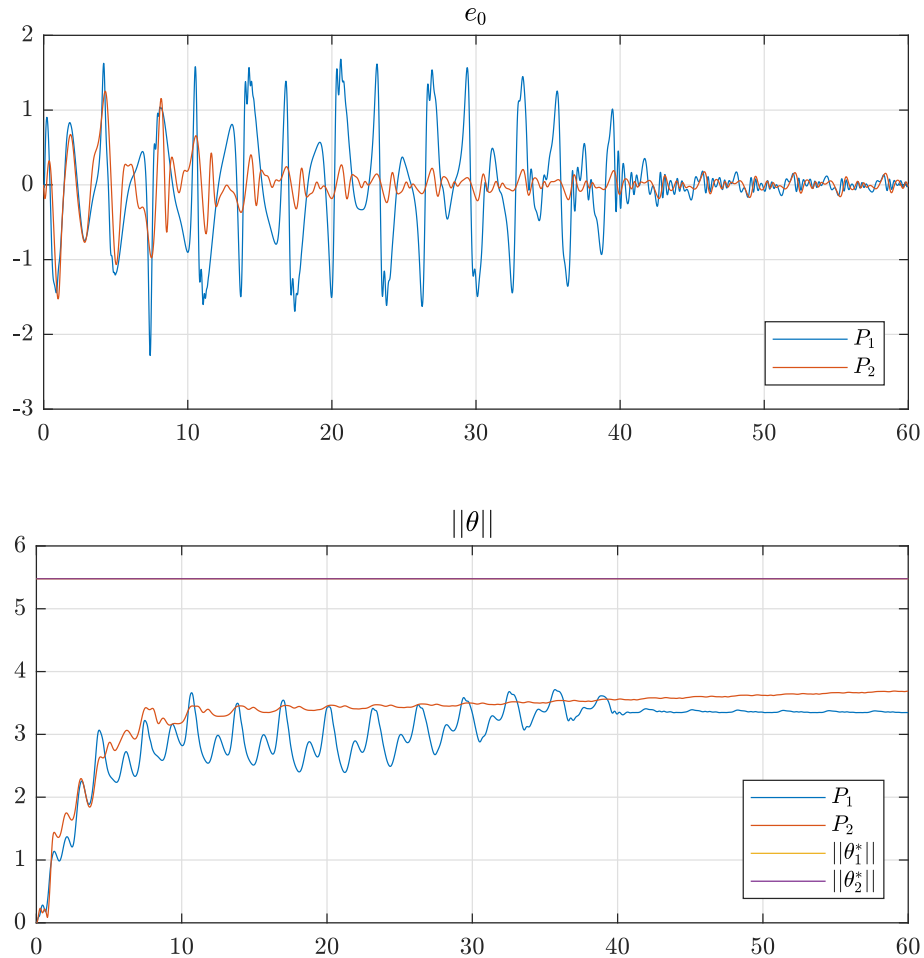
### 4.3 Simulação #3

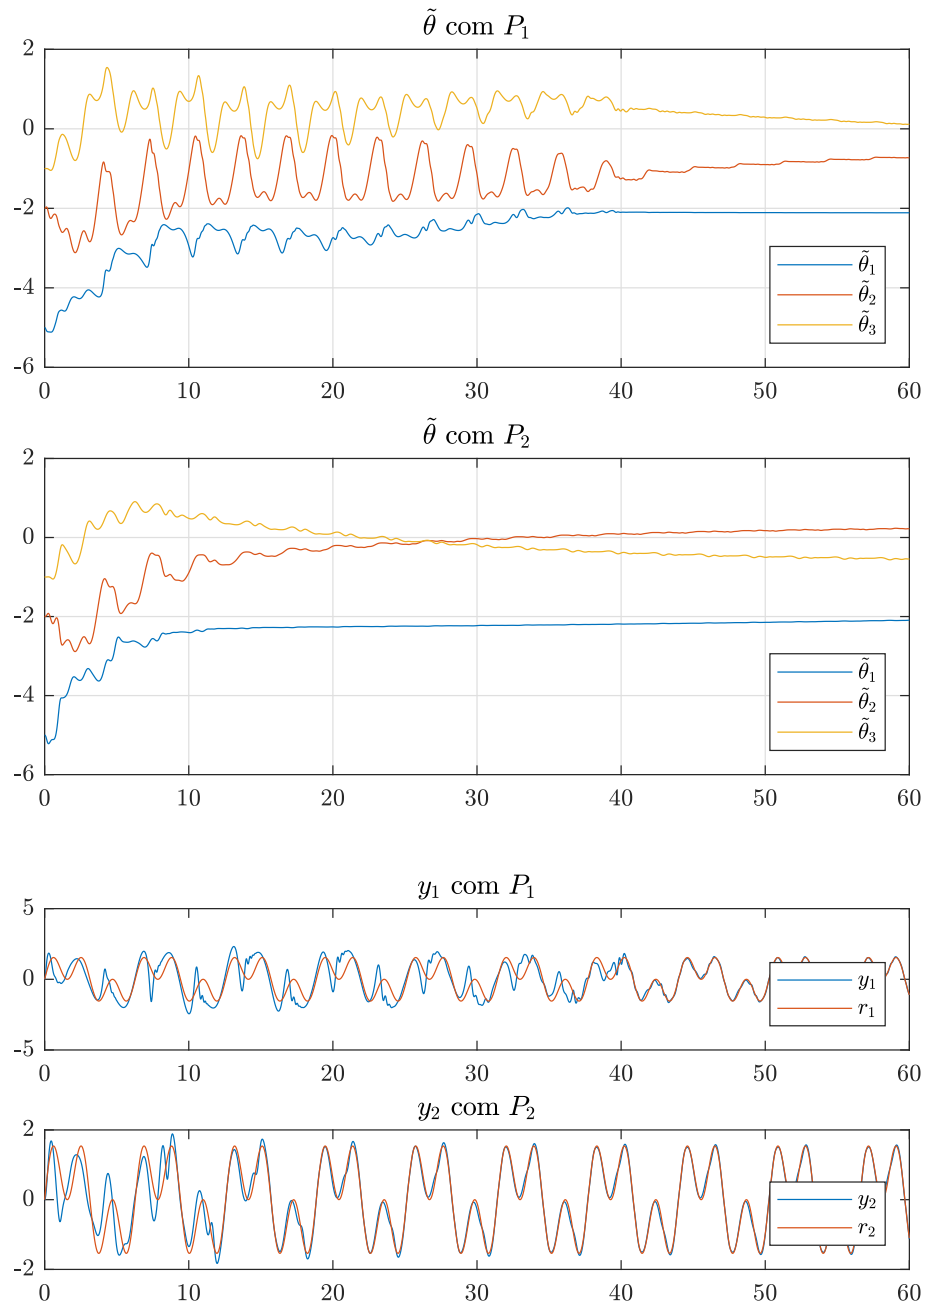
Verificamos o comportamento do sistema para variações na planta e modelo.

#### Simulação 3.1: planta

$$y = \frac{5}{s^2 + 2s + 1} u e \frac{5}{s^2 - 2s + 1} u, \quad \theta(0) = 0, \quad y(0) = 0, \quad \Gamma = 1 \mathbf{I}_3,$$

$$y_r = \sin(t) + \sin(3t).$$










### Simulação 3.2: modelo

$$y = \frac{5}{s^2 + 2s + 1}u \quad \theta(0) = 0, \quad y(0) = 0, \quad \Gamma = 1 \mathbf{I}_3,$$

$$y_r = \sin(t) + \sin(3t) \text{ e } \sin(t) + 2\sin(5t).$$







## 5 Discussão

A **simulação #1** mostra o comportamento do sistema para variações nas condições iniciais. A rapidez da convergência depende de quão próximo os parâmetros estimados estão dos parâmetros reais. A simulação mostrou um comportamento semelhante para ambos os casos. Quando deslocamos o  $y(0)$ , na simulação 1.2, os sistemas também apresentam comportamento semelhante, pois a variável de controle  $u$  é alterada e não apresenta saturação, compensando a condição inicial.

A **simulação #2** mostra o comportamento do sistema para variações no ganho de adaptação  $\Gamma$ . Podemos verificar convergência mais rápida quando o  $\Gamma$  é maior, porém também observamos maiores oscilações e picos de erro.

A **simulação #3** mostra o comportamento do sistema para variações na planta. Escolhemnos plantas instáveis e estáveis. Podemos observar que, em ambos os casos, o sinal de controle foi capaz de corrigir o erro, sem muitas dificuldades. O comportamento dos sistemas é semelhante. A alteração do modelo, na simulação 3.2, mostrou que modelos mais complexos, com frequências mais altas e maiores amplitudes, demoram mais para convergir.